



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
گرایش هوش مصنوعی

عنوان

تولید دنباله با استفاده از شبکه‌های مقابله‌ای

نگارش

احسان منتهائی

استاد راهنما

دکتر مهدیه سلیمانی

زمستان ۱۳۹۷

دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد

تولید دنباله با استفاده از شبکه‌های مقابله‌ای

نگارش: احسان منتهائی

امضاء:

دکتر مهدیه سلیمانی

استاد راهنما:

امضاء:

دکتر حسین صامتی

استاد ممتحن داخلی:

امضاء:

دکتر عمادالدین فاطمی‌زاده

استاد ممتحن خارجی:

چکیده

دنباله‌ها بخش زیادی از اطلاعات دنیای واقعی را تشکیل می‌دهند، که بارزترین نمونه‌ی آن زبان‌های طبیعی است. بسیاری از ساختارهای مهم نیز قابلیت مدل شدن به عنوان دنباله را داشته و داده‌هایی مثل ساختار مولکول، گراف و نت‌های موسیقی را نیز می‌توان به عنوان دنباله در نظر گرفت. از سوی دیگر تولید دنباله‌های جدید و بامعنی در هر حوزه، موضوعی با اهمیت و کاربردی است، مثلاً در ترجمه‌ی زبان طبیعی یا کشف ساختار داروی جدید با ویژگی‌های خاص، مساله‌ی تولید دنباله وجود دارد. با این وجود مشکلات مهم زیادی برای حل مساله‌ی تولید دنباله مطرح است، از جمله این مشکلات می‌توان به گسسته بودن جنس داده‌ها و انتخاب تابع هدف مناسب اشاره کرد. روش‌های پایه‌ی ارائه‌شده در این حوزه، دارای مشکلاتی نظیر اُریبی مواجهه میان زمان آموزش و آزمون و تابع هدف نامناسب هستند، از این رو نیاز به روش‌های جدید در این حوزه احساس می‌شود.

در چند سال اخیر پیشرفت‌های زیادی در حوزه‌ی تولید تصویر به وسیله‌ی شبکه‌های مولد مقابله‌ای انجام شده است. همین موضوع باعث شده که استفاده از شبکه‌های مولد مقابله‌ای در تولید دنباله‌ها نیز به تازگی مورد توجه قرار گیرد. اما به دلیل گسسته بودن جنس دنباله‌ها، این امر به سادگی میسر نبوده و برای حل آن نیاز به استفاده از راهکارهایی مثل یادگیری تقویتی و استفاده از تقریب وجود دارد. به علاوه ناپایداری شبکه‌های مولد مقابله‌ای باعث ایجاد چالش‌های جدید و زیاد شدن پیچیدگی مساله می‌شود.

در این پژوهش، با بیان رویکردی جدید و مبتنی بر ایده‌ی شبکه‌های مولد مقابله‌ای، به ارائه‌ی روشی برای حل مساله‌ی تولید دنباله با رویکردی تکرار شونده می‌پردازیم، به طوری که مدل در هر گام الگوریتم، با آموزش در مقابل نمونه‌های تولیدی خودش بهبود می‌یابد. اساس روش پیشنهادی تخمین نسبت چگالی احتمال بوده و با این رویکرد روشی بدون مشکل در برابر گسستگی دنباله‌ها ارائه شده است. راهکار ارائه شده نسبت به روش‌های شبکه‌های مولد مقابله‌ای در حوزه‌ی دنباله، آموزشی پایدارتر دارد؛ هم‌چنین مشکل اُریبی مواجهه نیز در روش پیشنهادی وجود ندارد.

از آنجا که ارزیابی مدل‌های مولد خود چالشی مورد تحقیق است، در بخش دیگری از پایان‌نامه به بررسی معیارهای موجود پرداخته و با ارائه سه نحوه‌ی ارزیابی جدید، سعی در رفع مشکل معیارهای موجود و بهره بردن از نتایج پژوهش‌های مربوط به حوزه‌ی تصویر داریم. روش‌های ارزیابی پیشنهادی برخلاف معیارهای پیشین که فقط کیفیت نمونه‌ها را بررسی می‌کنند، همزمان به تنوع نمونه‌های تولیدی در کنار کیفیت اهمیت می‌دهند. آزمایش‌های این پژوهش نشان‌دهنده‌ی برتری روش پیشنهادی در مقابل روش‌های پیشین است.

کلمات کلیدی: شبکه‌های مقابله‌ای، ایجاد دنباله، شبکه‌های عصبی، یادگیری عمیق

فهرست مطالب

۱	مقدمه	۱
۱-۱	تعریف مساله	۱
۲-۱	اهمیت و کاربرد	۲
۳-۱	یادگیری مقابله‌ای	۳
۱.۳-۱	دلیل توجه به یادگیری مولدمقابله‌ای	۳
۴-۱	چالش‌ها	۵
۱.۴-۱	مشخص نبودن معیار ارزیابی مناسب	۵
۲.۴-۱	مشخص نبودن تابع هزینه مناسب	۵
۳.۴-۱	ناهماهنگی آموزش و آزمون	۶
۴.۴-۱	مشکل انتقال گرادیان	۷
۵.۴-۱	ناپایداری آموزش مقابله‌ای	۸
۵-۱	هدف پژوهش	۹
۶-۱	ساختار پایان‌نامه	۱۰
۲	پژوهش‌های پیشین	۱۱
۳	راهکار پیشنهادی	۱۲
۴	معیارهای ارزیابی پیشین و پیشنهادی	۱۳
۵	ارزیابی	۱۴
۶	جمع‌بندی و کارهای آتی	۱۵

- آ جزئیات بررسی نظری روش پیشنهادی ۱۷
- ب آزمایش‌های بیشتر ۱۸
- مراجع ۱۹
- واژه‌نامه فارسی به انگلیسی ۲۲
- واژه‌نامه انگلیسی به فارسی ۲۳

فهرست شکل‌ها

- ۱-۱ نتایج یکی از آخرین پژوهش‌های انجام شده در حوزه‌ی تصویر با کمک شبکه‌های مولد مقابله‌ای ۴
- ۲-۱ مقایسه رفتار بیشینه درست‌نمایی و معکوس فاصله‌ی ۶
- ۳-۱ نمایش یک نمونه تابع از مقدار پیوسته‌ی دو بعدی به یک مقدار گسسته ۸
- ۴-۱ نمایش ناپایداری آموزش شبکه‌های مولد مقابله‌ای و پایدارکردن آن ۹

فهرست جدول‌ها

فصل ۱

مقدمه

مطالب این فصل

۱-۱	تعریف مساله	۱
۲-۱	اهمیت و کاربرد	۲
۳-۱	یادگیری مقابله‌ای	۳
۴-۱	چالش‌ها	۵
۵-۱	هدف پژوهش	۹
۶-۱	ساختار پایان‌نامه	۱۰

در این فصل ابتدا به معرفی مساله‌ی تولید دنباله می‌پردازیم، اهمیت و کاربردهای این مساله را مورد بررسی قرار می‌دهیم. پس از آن به صورت مختصر درباره‌ی یادگیری مقابله‌ای^۲ و دلیل توجه به آن توضیحاتی می‌دهیم. سپس چالش‌هایی ذاتی مساله، چالش‌هایی که در روش‌های پایه برای حل مساله وجود داشته و چالش‌های ایجاد شده با استفاده از یادگیری مقابله‌ای بیان می‌شود و فصل حاضر را با تشریح ساختار پایان‌نامه و فصول مختلف آن به پایان می‌بریم.

۱-۱ تعریف مساله

در این پژوهش هدف تولید دنباله‌های گسسته با آموزش بر روی نمونه‌هایی که از این دنباله داریم است. دنباله‌ی گسسته به معنی تعدادی متغیر گسته است که ترتیب دارند و گسسته بودن دنباله به این معنی است که هر مقدار دنباله مقادیر محدودی می‌گیرد. در این پژوهش داده‌ی گسسته از نوع دسته‌ای^۳ مدنظر است (در مقابل داده‌های عددی مثل مجموعه‌ی اعداد صحیح). در داده‌های دسته‌ای همه‌ی مقادیر ممکن هم‌فاصله است، از این رو معمولاً این مقادیر به صورت بردار یک-فعال^۴ کد می‌شوند. هر یک از این مقادیر در دنباله را کلمه می‌نامیم.

^۲ Adversarial

^۳ Categorical

^۴ One-hot

۳-۱ یادگیری مقابله‌ای

شبکه‌های مولد مقابله‌ای^۱ [۶] روشی برای آموزش مدل مولد^۲ است بر این مبنا که شبکه‌هایی با هم رقابت می‌کنند و به نوعی با هم بازی انجام می‌دهند؛ نتیجه‌ی این رقابت آموزش مدل مولد است. روش‌های آموزش مبتنی بر این ایده را یادگیری مقابله‌ای می‌نامیم. در ادامه به نحوه‌ی کار روش شبکه‌های مولد مقابله‌ای معرفی شده در [۶] می‌پردازیم و سپس چند دلیل برای اهمیت یادگیری مقابله‌ای ذکر می‌کنیم.

در شبکه‌های مولد مقابله‌ای برای آموزش مدل مولد از شبکه‌ی دومی به عنوان تمیزدهنده^۳ استفاده می‌شود، این شبکه یک دسته‌بند^۴ دو دسته‌ای است. روال آموزش به این صورت است که تمیزدهنده بین دو مجموعه داده‌ی واقعی و داده‌های تولید شده توسط مولد دسته‌بندی انجام می‌دهد، سپس شبکه‌ی مولد به سمتی سوق داده می‌شود که تمیزدهنده را به اشتباه بیاندازد و این دو مرحله به صورت تکراری انجام می‌شود. در این روش آموزش تمیزدهنده مشابه یک دسته‌بند عادی انجام می‌شود. از آنجا که شبکه‌ی تمیزدهنده نسبت به ورودی مشتق‌پذیر است برای آموزش مدل مولد، گرادینان از شبکه‌ی تمیزدهنده وارد شده و پارامترهای مدل مولد را به‌روزرسانی می‌کند، به عبارت دیگر شبکه‌ی تمیزدهنده مشابه تابع هزینه برای مولد عمل کرده و مشخص می‌کند با تغییر پارامترهای مولد در چه راستایی تمیزدهنده به اشتباه می‌افتد.

۱.۳-۱ دلیل توجه به یادگیری مولد مقابله‌ای

برای حل مسأله‌ی تولید دنباله توجه زیادی به آموزش مقابله‌ای شده است [۲، ۵، ۷-۱۳]، در ادامه دلایلی برای این موضوع ذکر می‌کنیم.

- پیشرفت‌های چشم‌گیر یادگیری مقابله‌ای در حوزه‌ی تصویر: بعد از معرفی یادگیری مقابله‌ای، این روش در حوزه‌ی تولید تصویر نتایج مرز دانش^۵ را کسب کرده است و هر روزه شاهد پیشرفت‌های بیشتری در این حوزه با کمک یادگیری مقابله‌ای هستیم.
- برای مثال در یکی از جدیدترین پژوهش‌هایی که توسط یک شرکت بزرگ ساخت کارت‌های گرافیکی بر روی تولید تصویر صورت انسان انجام شده است [۱۴]، نتیجه‌ی این پژوهش علاوه بر کسب امتیاز بالایی در معیار ارزیابی مربوط به آن حوزه، موفق به تولید تصاویر بسیار نزدیک به تصاویر واقعی شده است. به طوری که نمونه‌های ارائه شده در مقاله بسیار باکیفیت هستند و مصنوعی بودن آن غیرقابل تشخیص است، در شکل ۱-۱ (آ) دو نمونه از این تصاویر نمایش داده شده است. به علاوه فضای نهان^۶ که بر روی تصاویر صورت به دست آمده با معنی بوده و قابلیت ترکیب تصاویر تولید شده را می‌دهد، برای مثال شکل ۱-۱ (ب) نشان دهنده‌ی چند تصویر ورودی در سطر اول است که با کمک فضای ویژگی به دست آمده، به سبک^۷ تصویر سمت چپ تبدیل شده‌اند. به این ترتیب، به واسطه‌ی عملکرد مناسب این روش‌ها در حوزه‌ی

^۱ Generative Adversarial Networks

^۲ Generative

^۳ Discriminator

^۴ Classifier

^۵ State-of-the-Art

^۶ Latent

^۷ Style



(آ) تصاویر مصنوعی تولید شده



(ب) ادغام تصاویر در فضای ویژگی و تبدیل تصاویر مبدا به سبک تصویر مقصد

شکل ۱-۱: نتایج یکی از آخرین پژوهش‌های انجام شده در حوزه‌ی تصویر با کمک شبکه‌های مولد مقابله‌ای [۱۴]

تولید تصویر، در دو سال اخیر توجه به سمت استفاده از مدل‌های مولد مقابله‌ای در حوزه‌ی تولید متن هم جلب شده است.

- قابلیت استفاده از دسته‌ی بزرگی از فاصله‌ها: اثبات شده است که آموزش به وسیله‌ی شبکه‌های مولد مقابله‌ای، معادل کاهش فاصله‌ی Jensen-Shannon بین توزیع اصلی و توزیع مولد است [۶]. هم‌چنین روش‌های مبتنی بر یادگیری مقابله‌ای برای کاهش فاصله‌های دیگر هم پیشنهاد شده است [۱۵، ۱۶]. این فاصله‌ها روش مستقیم برای استفاده به عنوان تابع هزینه^۱ ندارند و این امر با کمک یادگیری مقابله‌ای محقق شده است.

- کمک به حل بعضی مشکلات موجود در روش‌های پایه: در روش‌های پایه‌ی تولید دنباله مشکلاتی مثل اُریبی مواجهه^۲ وجود دارد که دلیل آن رفتار متفاوت مولد در دو فاز آموزش^۳ و آزمون^۴ است. در ادامه در بخش چالش‌ها بیشتر به این موضوع می‌پردازیم. معمولاً روش یادگیری مقابله‌ای دچار این مشکل نمی‌شوند، زیرا اکثر این روش‌ها فاز آموزش و آزمون یکسانی برای تولید دنباله دارند.

^۱ Cost Function

^۲ Exposure Bias

^۳ Train

^۴ Test

۴-۱ چالش‌ها

در این بخش ابتدا به چالش معیار ارزیابی و تابع هزینه که چالش ذاتی مساله است می‌پردازیم، در ادامه نمونه‌ای از مشکل روش پایه را بیان کرده و در پایان مشکلات استفاده از یادگیری مقابله‌ای را در مساله بیان می‌کنیم.

۱.۴-۱ مشخص نبودن معیار ارزیابی مناسب

در حوزه‌ی مدل‌های مولد معیار ارزیابی مشخصی وجود ندارد و نحوه‌ی ارزیابی این مدل‌ها خود یک چالش است [۱۷]. ارزیابی مدل‌های مولد دنباله هم از این قاعده مستثنی نیست و معیاری استاندارد به جز قضاوت انسانی وجود ندارد. به دلیل اهمیت معیار ارزیابی، فصل ۴ به این موضوع اختصاص داده شده است.

۲.۴-۱ مشخص نبودن تابع هزینه مناسب

مشکلی مشابه در حوزه‌ی انتخاب تابع هزینه مورد استفاده وجود دارد و بخش عمده‌ای از پژوهش‌های انجام شده در حوزه‌ی تولید دنباله به روش‌های آموزش و تابع‌های هزینه اختصاص دارد. تابع هدف^۱ اولیه مورد استفاده در روش‌های پایه مبتنی بر بیشینه درست‌نمایی^۲ است. این تابع هدف به این معنی است که در آموزش مدل، هدف افزایش احتمالی است که مدل به داده‌های آموزش می‌دهد و به سمتی می‌رود که از دید مدل، داده‌های واقعی احتمال بالایی بگیرند؛ ولی اینکه به دنبال مدل‌هایی باشیم که نمونه‌های تولیدی آن در توزیع واقعی داده‌ها (که در دسترس نیست) احتمال بالایی بگیرند، رویکرد منطقی‌تری است. با این وجود راه‌حلی برای استفاده از این تابع هدف وجود ندارد. روش‌های یادگیری مقابله می‌توانند استفاده از تابع هدف‌های بهتر را ممکن کنند [۱۸]. درست‌نمایی مدل را به سمتی می‌برد که به داده‌های آموزش احتمال بالایی دهد، ولی این موضوع را کمتر در نظر می‌گیرد که به نمونه‌های غیر از داده‌های آموزش احتمال کمی نسبت دهد. این ویژگی می‌تواند منجر به رفتاری شود که به نمونه‌ی نامعتبری احتمال بالا نسبت داده شود، این رفتار به نام میانگین-جستجوگری^۳ شناخته می‌شود که در ادامه بیشتر توضیح داده شده است.

رفتار میانگین-جستجوگری

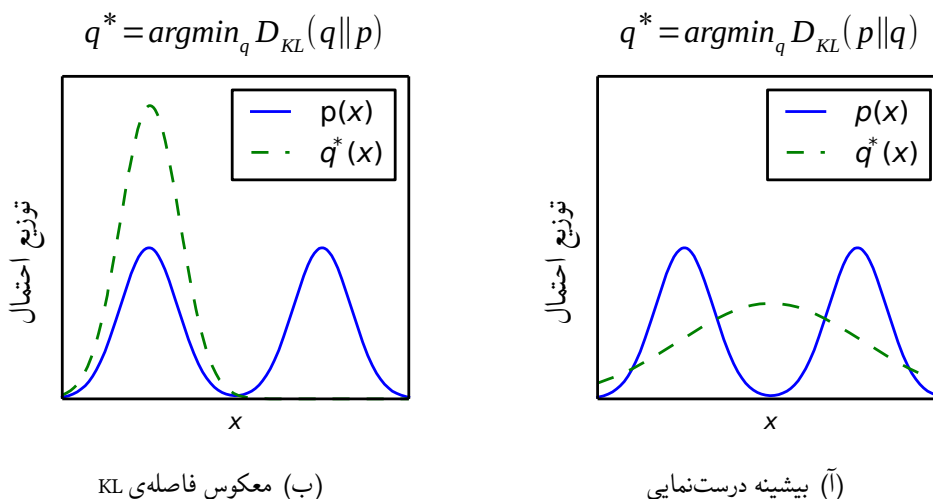
در حالتی که ظرفیت مدل به اندازه‌ی کافی است با در نظر گرفتن تابع درست‌نمایی به عنوان تابع هدف می‌توان توزیع داده‌ی اصلی را یاد گرفت. ولی در حالتی که ظرفیت مدل در مقابل داده‌های آموزش کم است مدل نمی‌تواند توزیع اصلی را کاملاً یاد بگیرد و بسته به تابع هزینه رفتارهای متفاوتی را بروز می‌دهد. رفتاری که با تابع هدف درست‌نمایی بروز داده می‌شود باعث می‌شود توزیع آموزش دیده کل توزیع داده اصلی را در بر بگیرد و در این بین ممکن است به نقاطی از فضا بیشترین احتمال را نسبت دهد که داده‌های اصلی در آنجا احتمال کمی دارند. این رفتار میانگین-جستجوگری نامیده می‌شود. در حوزه‌ی مدل‌های مولد این رفتار به این معنی است که مدل می‌خواهد

^۱ Objective Function

^۲ Maximum Likelihood

^۳ Mean-Seeking

داده‌هایی شبیه به تمام داده‌های آموزش تولید کند، حتی به این قیمت که بعضی از داده‌های تولیدی شبیه به داده‌های آموزش نباشد [۱۸]. به صورت کلی‌تر رفتار میانگین-جستجوگری مربوط به استفاده فاصله‌ی Kullback-Leibler (KL) بین توزیع داده اصلی و توزیع مدل به عنوان تابع هزینه است، در ادامه دلیل این رفتار بیان شده است.



شکل ۲-۱: مقایسه رفتار بیشینه درست‌نمایی و معکوس فاصله‌ی

برای توجیه رفتار میانگین-جستجوگری، حالتی را در نظر بگیرید که این رفتار رخ ندهد یعنی محلی در فضا توزیع احتمال داده‌ی اصلی مقدار دارد و توزیع مدل به آن نقطه احتمال صفر نسبت داده است، در این شرایط تابع هزینه به سمت بی‌نهایت می‌رود و بنابراین در آموزش از چنین حالتی دوری می‌شود و هر نقطه از فضای داده که احتمال دارد، باید مدل هم احتمالی به آن نقطه نسبت دهد.

به عنوان یک مثالی از این رفتار، اگر فرض کنیم داده‌های واقعی توزیع دو قله‌ای گاوسی دارند و خانواده‌ی مدل مولدی که در نظر گرفته‌ایم گاوسی تک قله‌ای باشد، در شکل ۲-۱(آ) نتیجه آموزش با شرایط گفته شده نشان داده شده است، که $p(x)$ توزیع واقعی داده‌ها و $q^*(x)$ بهینه است. نتیجه آموزش با درست‌نمایی در این حالت باعث شده مدل به نقطه‌ای از فضا احتمال زیادی دهد که داده‌های اصلی احتمال کمی دارند. شکل ۲-۱(ب) حالتی است که معکوس فاصله‌ی KL کمینه شده و به سمتی رفته که یکی از قله‌های توزیع اصلی را یاد بگیرد که از یک جهت رفتار مناسب‌تری است. به عبارت دیگر این حالت باعث تولید نمونه‌ی نامعتبر نمی‌شود ولی می‌تواند تنوع در نمونه‌های تولیدشده را محدود کند.

۳.۴-۱ ناهماهنگی آموزش و آزمون

در برخی از روش‌ها نمی‌توان رفتار مشابه در آموزش و آزمون داشت که این مساله باعث می‌شود که خطایی در آموزش ایجاد شود. در ادامه به ذکر یک نمونه از این مشکل می‌پردازیم.

در اکثر روش‌ها برای تولید دنباله، مساله ساده‌سازی می‌شود و به این شکل تبدیل می‌شود که با داشتن یک زیردنباله عنصر بعدی دنباله چگونه باید باشد. بنابراین اگر در گام آموزش این زیردنباله‌ها فقط داده‌های واقعی باشند مشکل

ناهماهنگی^۱ آموزش و آزمون پیش می‌آید، زیرا مدل فقط تصمیم‌گیری با دنباله‌های کاملاً صحیح را آموزش دیده ولی در گام آزمون با زیردنباله‌های تولید خودش مواجه می‌شود، این مشکل اُریبی مواجهه نامیده می‌شود.

۴.۴-۱ مشکل انتقال گرادیان

راهکارهای زیادی برای استفاده از یادگیری مقابله‌ای در حوزه‌ی داده‌های پیوسته پیشنهاد و استفاده شده است، ولی به دلیل مشکل انتقال گرادیان در داده‌های گسسته، مستقیماً امکان استفاده از این روش‌ها در حوزه‌ی داده‌های گسسته وجود ندارد.

روش بهینه‌سازی که برای آموزش شبکه‌های عصبی استفاده می‌شود مبتنی بر محاسبه‌ی گرادیان نسبت به پارامترهای شبکه است و روش‌های یادگیری مقابله‌ای هم نیازمند محاسبه‌ی این گرادیان هستند. برای به‌روزرسانی شبکه مولد لازم است که نمونه‌های تولید شده توسط شبکه‌ی مولد وارد دسته‌بند شده، سپس با کمک دسته‌بند تغییر پارامترهای شبکه‌ی مولد در جهتی که شبکه‌ی دسته‌بند فریب بخورد (یا همان گرادیان)، محاسبه شود. برای اینکه گرادیان نسبت به پارامترهای شبکه‌ی مولد قابل محاسبه باشد، باید تمام عملیات ایجاد نمونه و محاسبه‌ی خروجی دسته‌بند دارای مشتق تعریف شده باشند.

در مساله‌ی تولید دنباله معمولاً در انتهای شبکه‌ی مولد نیاز به نمونه‌گیری از یک توزیع است، این عملیات مشتق تعریف شده‌ای ندارد که این موضوع باعث بروز مشکل انتقال گرادیان می‌شود [۵]. مشکل انتقال گرادیان به معنی عدم توانایی انتقال گرادیان تولید شده توسط دسته‌بند به شبکه‌ی مولد است. این چالش تنها مربوط به حوزه‌ی یادگیری مقابله‌ای نبوده و برای تقریب گرادیان پژوهش‌هایی مثل [۱۹] انجام شده است. در ادامه دلایل این مشکل با جزئیات بیشتر تشریح شده است.

تعریف نشده بودن مشتق عملیات تصادفی

زمانی که متغیر تصادفی z تابعی از θ است و این رابطه تصادفی است، در حالت کلی مشتق z نسبت به θ تعریف نشده است. این مشکل در خود رمزگذار وردشی^۲ هم وجود داشته و راه حل تنظیم مجدد^۳ برای آن پیشنهاد شده است [۱۹].

برای مثال، یک نمونه استفاده از این تکنیک در رابطه با توزیع گوسی است، فرض کنید متغیر تصادفی z به طوری تعریف می‌شود که $z \sim N(f_\theta, 1)$ باشد، در حالت عادی مشتق z به پارامتر θ تعریف نشده است ولی با بازنویسی z به صورت $f_\theta + N(0, 1)$ مشکل حل شده و با حذف قسمت تصادفی از مسیر تبدیل θ به z مشتق تعریف شده است. متأسفانه در شبکه‌های مولد مقابله‌ای برای تولید دنباله، این مشکل به راحتی قابل حل نیست. در بخش؟؟ توضیحات بیشتری در این رابطه بیان شده است.

^۱ Inconsistency


^۲ Variational Autoencoder

^۳ Reparametrization

گسسته بودن خروجی شبکه

مشکل عدم وجود مشتق در مثال گاوسی به این دلیل قابل حل بوده که بعد از تکنیک تنظیم مجدد در مسیر تبدیل θ به z تمام عملیات مشتق‌پذیر است. در حالی که در تولید دنباله گسستگی مقادیر، تعریف دقیق مشتق را ناممکن می‌کند و تنها راهکارهای تقریبی ممکن هستند. شبکه‌ای که در مساله‌ی تولید دنباله گسسته استفاده می‌شود نیازمند تولید داده‌های گسسته است و بنابراین خروجی شبکه‌ی مولد نوع گسسته دارد.

مشکل گسسته بودن خروجی عملیات را از دو دیدگاه می‌توان بیان کرد. دیدگاه اول اینکه برای مشتق این عملیات راه حلی نداریم و راه عملی برای انجام آن وجود ندارد. برای مثال در نظر بگیرید رابطه‌ی $z = \arg \max_i f_i(\theta)$ برای z برقرار است و می‌خواهیم مشتق z نسبت به θ را محاسبه کنیم که روش برای آن نداریم. دیدگاه دوم به صورت بررسی هندسی است، فرض کنید تابع f به صورت $z = f(\theta)$ تعریف شده است و خروجی آن گسسته است، یعنی z دارای N حالت ممکن است. فضایی که پارامترهای θ می‌سازند را در نظر بگیرید، از آنجا که در کل N حالت خروجی وجود دارد، بنابراین فضای پارامترهای θ به N بخش افراز می‌شود. اگر θ نقطه‌ای در یکی از نواحی فضا باشد با تغییرات محلی در مقدار θ خروجی تغییری نمی‌کند و مشتق معنی ندارد [۵]، شکل ۱-۳ توصیفی از چنین فضایی است.




شکل ۱-۳: نمایش یک نمونه تابع از مقدار پیوسته‌ی دو بعدی به یک مقدار گسسته، در چنین فضایی روش‌های مبتنی بر گرادیان برای پیدا کردن نقطه‌ی بیشینه کارساز نیست.

۵.۴-۱ ناپایداری آموزش مقابله‌ای


بزرگترین چالشی که در روش‌های آموزش مقابله‌ای وجود دارد ناپایداری آموزش آن است. دو نمونه از این ناپایداری به شرح زیر است:

- آموزش مقابله‌ای می‌تواند به رفتار ناپایداری منجر شود که توزیع مدل مولد بین چند قله از توزیع اصلی به صورت تناوبی جابجا شود که این رفتار چسبیدگی به قله^۱ نام دارد. یک مثال از چسبیدگی به قله در شکل ۱-۴(آ) نشان داده شده است و نشان می‌دهد که در آموزش یک توزیع چندقله‌ای به عنوان توزیع اصلی،

^۱ Mode Collapsing



(آ) آموزش ناپایدار



(ب) آموزش پایدار

شکل ۱-۴: نمایش ناپایداری آموزش شبکه‌های مولد مقابله‌ای و پایدارکردن آن با روش معرفی شده در [۲۰]. تصویر سمت راست توزیع داده‌ی اصلی را نشان می‌دهد و بقیه تصاویر از چپ به راست توزیع مدل مولد در حین آموزش و در گام‌های ۵۰۰۰، ۱۰۰۰۰ و ۲۰۰۰۰ آموزش است.

مدل مولد بین قله‌ها به صورت تناوبی جابجا می‌شود. هم‌چنین شکل ۱-۴ (ب) نشان دهنده‌ی حالتی است که با تکنیک معرفی شده در [۲۰]، این آموزش پایدار شده است.

- مشکل دیگر در تکنیک مطرح‌شده در تنظیم نسبت آموزش مدل مولد و تمیزدهنده است. به این صورت که اگر مدل تمیزدهنده به خوبی آموزش ببیند تمام نمونه‌های مدل مولد را به راحتی تشخیص می‌دهد و این موضوع باعث سخت شدن آموزش مولد می‌شود. مثلاً فرض کنید شبکه‌ی مولد بر اساس امتیازی که از تمیزدهنده می‌گیرد آموزش می‌بیند و در حالتی که تمیزدهنده خیلی قوی‌تر باشد به همه‌ی حرکت‌های خوب مولد امتیاز بسیار کوچکی می‌دهد که این موضوع باعث آموزش ندیدن مولد در عمل می‌شود. در واقع نزدیک نقطه‌ی بهینه برای تمیزدهنده، گرادیان نزدیک صفر است و چندان نمی‌تواند به بهبود مولد کمک کند.

برای پایدار کردن آموزش روش‌هایی ارائه شده است [۲۰-۲۵]، ولی بسیاری از این روش‌ها خاص حوزه‌ی داده‌های پیوسته است و نمی‌توان از آنها در تولید دنباله مستقیماً بهره برد.

۵-۱ هدف پژوهش

با توجه به تعریف مساله در بخش ۱-۱ و چالش‌هایی که برای حل آن وجود دارد، در ادامه قصد داریم روشی برای تولید دنباله ارائه کنیم که بر پایه‌ی شبکه‌های مولد مقابله‌ای است، اما با مشکلاتی نظیر انتقال گرادیان رو به رو نیست. هم‌چنین در جهت ارزیابی موثرتر مدل پیشنهادی، معیارهای سنجش کیفیت را مورد مطالعه‌ی دقیق قرار داده و معیارهای جدیدی را برای این منظور پیشنهاد می‌کنیم.

۶-۱ ساختار پایان‌نامه

در ادامه‌ی مستند حاضر، در فصل دوم به تشریح کارهای پیشین در زمینه‌ی تولید دنباله می‌پردازیم و با بررسی مزایا و معایب این روش‌ها، رویکردهای مختلف حل این مساله را با یکدیگر مقایسه می‌کنیم و در فصل سوم راهکار پیشنهادی برای تولید دنباله را معرفی می‌کنیم. از آنجا که معیار ارزیابی خود موضع چالش برانگیزی در این حوزه است فصل چهار را به تشریح این معیارها می‌پردازیم و معیارهای جدیدی را پیشنهاد می‌کنیم. با ارائه آزمایش‌های انجام شده در فصل پنجم، به ارزیابی روش پیشنهادی می‌پردازیم. در نهایت با جمع‌بندی مطالب ارائه شده و ارائه پیشنهاداتی برای ادامه پژوهش، پایان‌نامه را به پایان می‌بریم.

فصل ۲

پژوهش‌های پیشین

فصل ۳

راهکار پیشنهادی

فصل ۴

معیارهای ارزیابی پیشین و پیشنهادی

فصل ۵

ارزیابی

فصل ۶

جمع‌بندی و کارهای آتی

در این پژوهش جدیدترین کارهای پیشین در حوزه‌ی تولید دنباله مورد بررسی قرار گرفت و برخی از مزایا و معایب آنها بررسی شد. معیارهایی که روش‌های گذشته برای اثبات بهبودهای خود استفاده کرده‌اند، مورد نقد و بررسی قرار گرفت و مشاهده شد که معیارهای مورد استفاده در برخی از روش‌ها، قضاوت ناعادلانه‌ای را انجام داده‌اند. این مشکل ریشه در ارزیابی کیفیت نمونه‌های تولیدی بدون توجه به تنوع آنها دارد. از این رو چند معیار جدید برای رفع این مشکل بیان و آزمایش‌هایی بر مبنای این معیارها انجام شد. در آزمایش‌ها، کیفیت بالا و تنوع کم نتایج روش‌های مبتنی بر شبکه‌های مولد مقابله‌ای نشان داده شد و به این جمع‌بندی رسیدیم که روش‌های پیشین بر اساس یادگیری مقابله‌ای در معیارهایی که همزمان کیفیت و تنوع را ارزیابی می‌کنند، پیشرفتی نسبت به روش پایه‌ی جبر معلم نداشته‌اند. به علاوه ناپایداری این روش‌ها در آموزش نشان داده شد، این موضوع خود می‌تواند دلیلی بر نتایج نامناسب این دسته از روش‌ها باشد.

روش پیشنهادی با ایده‌ی آموزش مولد توسط تمیزدهنده، بر مبنای تخمین نسبت چگالی دو توزیع معرفی و دو رویکرد برای این روش تشریح شد. هم‌گرایی هر دو رویکرد به شکل نظری مورد بررسی قرار گرفت. هم‌چنین دیدیم که رویکرد اول در آزمایش‌ها نتایج بهتری نسبت به دیگر روش‌ها کسب کرد و نشان داد که آموزش پایداری دارد. از سوی دیگر، رویکرد دوم به صورت نظری دقیق‌تر بررسی شد و نشان داده شد که با در نظر گرفتن فرض سبکی برای تمیزدهنده، در هر گام مولد بهبود اتفاق می‌افتد.

برای کارهای آینده، در سه مسیر می‌توان پژوهش را ادامه داد. مسیر اول، بررسی معیارهای پیشنهادی و معیارهای موجود است. این بررسی‌ها می‌تواند شامل بررسی مقاومت و حساسیت معیار باشد. برای نمونه، نیاز به بررسی تغییر معیار در مقابل تخریب دنباله‌ها است. هم‌چنین حساسیت معیار به نحو و یا معنای دنباله‌ها و بخصوص دنباله‌های زبان طبیعی جای بررسی بیشتر دارد. هم‌چنین بررسی‌های دیگری مثل اثر طول دنباله بر معیارها نیازمند مطالعه است.

مسیر دوم، بررسی بیش‌تر روش پیشنهادی از نظر عملی است. اینکه چه ساختارهایی مناسب شبکه‌ی تمیزدهنده است و هم‌چنین نحوه‌ی تاثیر تابع f انتخابی در تابع هزینه (که در تحلیل نظری روش گفته شد) در عمل چگونه است. به علاوه تعمیم روش به حالتی که هدف، تولید دنباله‌هایی به صورت شرطی باشد نیز می‌تواند مورد بررسی قرار بگیرد.

مسیر سوم، بهبود روش‌های پیشین است. زیرا در این پژوهش با مشکلاتی در روش‌های پیشین مواجه شدیم که مورد توجه نبوده است. امید می‌رود که حل این مشکلات موجب بهبود روش‌های پیشین در حوزه باشد. برای مثال

روش SegGAN از جستجوی مونت کارلو برای تخمین امتیاز زیر دنباله‌ها استفاده می‌کند، انتظار داریم بتوان مشابه روش پیشنهادی، با شبکه‌ای بازگردنده این تخمین مستقیماً محاسبه شود. به عنوان نمونه‌ای دیگر، متوجه شدیم که در روش‌های یادگیری مقابله‌ای با رویکرد تولید دنباله‌ی «توزیع کلمه» (بخش ۹؟)، اُریبی وجود دارد. این اُریبی در تفاوت آموزش و آزمون است. زیرا این روش‌ها در آموزش توزیع را تولید می‌کنند ولی در آزمون از $\arg \max$ توزیع تولیدی را برای تولید دنباله استفاده می‌کنند. امید می‌رود با استفاده از تکنیک‌های مشابه Gumbel Softmax این اُریب رفع شود.

پیوست
آ

جزئیات بررسی نظری روش پیشنهادی

پیوست ب آزمایش‌های بیشتر

مراجع

- [1] D. Weininger, "Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules," *Journal of chemical information and computer sciences*, vol. 28, no. 1, pp. 31–36, 1988.
- [2] G. L. Guimaraes, B. Sanchez-Lengeling, P. L. C. Farias, and A. Aspuru-Guzik, "Objective-reinforced generative adversarial networks (ORGAN) for sequence generation models," *CoRR*, vol. abs/1705.10843, 2017. [Online]. Available: <http://arxiv.org/abs/1705.10843>
- [3] A. Bojchevski, O. Shchur, D. Zügner, and S. Günnemann, "Netgan: Generating graphs via random walks," in *Proceedings of the 35th International Conference on Machine Learning, ICML 2018, Stockholmsmässan, Stockholm, Sweden, July 10-15, 2018*, 2018, pp. 609–618. [Online]. Available: <http://proceedings.mlr.press/v80/bojchevski18a.html>
- [4] J. You, R. Ying, X. Ren, W. L. Hamilton, and J. Leskovec, "Graphrnn: Generating realistic graphs with deep auto-regressive models," in *Proceedings of the 35th International Conference on Machine Learning, ICML 2018, Stockholmsmässan, Stockholm, Sweden, July 10-15, 2018*, 2018, pp. 5694–5703. [Online]. Available: <http://proceedings.mlr.press/v80/you18a.html>
- [5] L. Yu, W. Zhang, J. Wang, and Y. Yu, "Seqgan: Sequence generative adversarial nets with policy gradient," in *Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence, February 4-9, 2017, San Francisco, California, USA.*, 2017, pp. 2852–2858. [Online]. Available: <http://aaai.org/ocs/index.php/AAAI/AAAI17/paper/view/14344>
- [6] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. C. Courville, and Y. Bengio, "Generative adversarial nets," in *Advances in Neural Information Processing Systems 27: Annual Conference on Neural Information Processing Systems 2014, December 8-13 2014, Montreal, Quebec, Canada*, 2014, pp. 2672–2680. [Online]. Available: <http://papers.nips.cc/paper/5423-generative-adversarial-nets>
- [7] M. J. Kusner and J. M. Hernández-Lobato, "GANS for Sequences of Discrete Elements with the Gumbel-softmax Distribution," *arXiv e-prints*, p. arXiv:1611.04051, Nov. 2016. [Online]. Available: <https://arxiv.org/pdf/1611.04051.pdf>

- [8] A. M. Lamb, A. G. ALIAS PARTH GOYAL, Y. Zhang, S. Zhang, A. C. Courville, and Y. Bengio, "Professor forcing: A new algorithm for training recurrent networks," in *Advances in Neural Information Processing Systems 29*, D. D. Lee, M. Sugiyama, U. V. Luxburg, I. Guyon, and R. Garnett, Eds. Curran Associates, Inc., 2016, pp. 4601–4609. [Online]. Available: <http://papers.nips.cc/paper/6099-professor-forcing-a-new-algorithm-for-training-recurrent-networks.pdf>
- [9] Y. Zhang, Z. Gan, K. Fan, Z. Chen, R. Henao, D. Shen, and L. Carin, "Adversarial feature matching for text generation," in *Proceedings of the 34th International Conference on Machine Learning, ICML 2017, Sydney, NSW, Australia, 6-11 August 2017*, 2017, pp. 4006–4015. [Online]. Available: <http://proceedings.mlr.press/v70/zhang17b.html>
- [10] K. Lin, D. Li, X. He, Z. Zhang, and M.-T. Sun, "Adversarial ranking for language generation," in *Advances in Neural Information Processing Systems*, 2017, pp. 3155–3165.
- [11] J. Guo, S. Lu, H. Cai, W. Zhang, Y. Yu, and J. Wang, "Long text generation via adversarial training with leaked information," in *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, (AAAI-18), the 30th innovative Applications of Artificial Intelligence (IAAI-18), and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence (EAAI-18), New Orleans, Louisiana, USA, February 2-7, 2018*, 2018, pp. 5141–5148. [Online]. Available: <https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/16360>
- [12] T. Che, Y. Li, R. Zhang, R. D. Hjelm, W. Li, Y. Song, and Y. Bengio, "Maximum-likelihood augmented discrete generative adversarial networks," *arXiv preprint arXiv:1702.07983*, 2017. [Online]. Available: <https://arxiv.org/pdf/1702.07983.pdf>
- [13] O. Press, A. Bar, B. Bogin, J. Berant, and L. Wolf, "Language generation with recurrent generative adversarial networks without pre-training," *arXiv preprint arXiv:1706.01399*, 2017.
- [14] T. Karras, S. Laine, and T. Aila, "A style-based generator architecture for generative adversarial networks," *arXiv preprint arXiv:1812.04948*, 2018.
- [15] S. Nowozin, B. Cseke, and R. Tomioka, "f-gan: Training generative neural samplers using variational divergence minimization," in *Advances in Neural Information Processing Systems 29: Annual Conference on Neural Information Processing Systems 2016, December 5-10, 2016, Barcelona, Spain*, 2016, pp. 271–279. [Online]. Available: <http://papers.nips.cc/paper/6066-f-gan-training-generative-neural-samplers-using-variational-divergence-minimization>
- [16] B. Poole, A. A. Alemi, J. Sohl-Dickstein, and A. Angelova, "Improved generator objectives for gans," *arXiv preprint arXiv:1612.02780*, 2016. [Online]. Available: <https://arxiv.org/pdf/1612.02780.pdf>

- [17] L. Theis, A. van den Oord, and M. Bethge, "A note on the evaluation of generative models," *CoRR*, vol. abs/1511.01844, 2015. [Online]. Available: <http://arxiv.org/abs/1511.01844>
- [18] F. Huszar, "How (not) to train your generative model: Scheduled sampling, likelihood, adversary?" *CoRR*, vol. abs/1511.05101, 2015. [Online]. Available: <http://arxiv.org/abs/1511.05101>
- [19] E. Jang, S. Gu, and B. Poole, "Categorical reparametrization with gumbel-softmax," in *International Conference on Learning Representations (ICLR)*, 2017. [Online]. Available: <https://openreview.net/pdf?id=rkE3y85ee>
- [20] L. Mescheder, S. Nowozin, and A. Geiger, "The numerics of gans," in *Advances in Neural Information Processing Systems 30*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds. Curran Associates, Inc., 2017, pp. 1825–1835. [Online]. Available: <http://papers.nips.cc/paper/6779-the-numerics-of-gans.pdf>
- [21] M. Arjovsky, S. Chintala, and L. Bottou, "Wasserstein GAN," *CoRR*, vol. abs/1701.07875, 2017. [Online]. Available: <http://arxiv.org/abs/1701.07875>
- [22] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, and A. C. Courville, "Improved training of wasserstein gans," in *Advances in Neural Information Processing Systems 30*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds. Curran Associates, Inc., 2017, pp. 5767–5777. [Online]. Available: <http://papers.nips.cc/paper/7159-improved-training-of-wasserstein-gans.pdf>
- [23] K. Roth, A. Lucchi, S. Nowozin, and T. Hofmann, "Stabilizing training of generative adversarial networks through regularization," in *Advances in Neural Information Processing Systems 30*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds. Curran Associates, Inc., 2017, pp. 2018–2028. [Online]. Available: <http://papers.nips.cc/paper/6797-stabilizing-training-of-generative-adversarial-networks-through-regularization.pdf>
- [24] L. Metz, B. Poole, D. Pfau, and J. Sohl-Dickstein, "Unrolled generative adversarial networks," *CoRR*, vol. abs/1611.02163, 2016. [Online]. Available: <http://arxiv.org/abs/1611.02163>
- [25] T. Salimans, I. Goodfellow, W. Zaremba, V. Cheung, A. Radford, X. Chen, and X. Chen, "Improved techniques for training gans," in *Advances in Neural Information Processing Systems 29*, D. D. Lee, M. Sugiyama, U. V. Luxburg, I. Guyon, and R. Garnett, Eds. Curran Associates, Inc., 2016, pp. 2234–2242. [Online]. Available: <http://papers.nips.cc/paper/6125-improved-techniques-for-training-gans.pdf>

واژه‌نامه فارسی به انگلیسی

Generative Adversarial Networks	شبکه‌های مولد مقابله‌ای	Test	آزمون
State-of-the-Art	مرز دانش	Train	آموزش
Adversarial	مقابله‌ای	Exposure Bias	اُریبی مواجهه
Generative	مولد	Maximum Likelihood	بیشینه درست‌نمایی
Mean-Seeking	میانگین-جستجوگری	Objective Function	تابع هدف
Inconsistency	ناهماهنگی	Cost Function	تابع هزینه
Latent	نهان	Discriminator	تمیزدهنده
One-hot	یک-فعال	Reparametrization	تنظیم مجدد
Mode Collapsing	چسبیدگی به قله	Variational Autoencoder	خود رمزگذار وردشی
Knowledge Graph	گراف دانش	Categorical	دسته‌ای
Random Walk	گشت‌زنی تصادفی	Classifier	دسته‌بند
		Style	سبک

واژه‌نامه انگلیسی به فارسی

Maximum Likelihood	بیشینه درست‌نمایی	Adversarial	مقابله‌ای
Mean-Seeking	میانگین-جستجوگری	Categorical	دسته‌ای
Mode Collapsing	چسبیدگی به قله	Classifier	دسته‌بند
Objective Function	تابع هدف	Cost Function	تابع هزینه
One-hot	یک-فعال	Discriminator	تمیزدهنده
Random Walk	گشت‌زنی تصادفی	Exposure Bias	اُریبی مواجهه
Reparametrization	تنظیم مجدد	Generative	مولد
State-of-the-Art	مرز دانش	Generative Adversarial Networks	شبکه‌های مولد
Style	سبک		مقابله‌ای
Test	آزمون	Inconsistency	ناهماهنگی
Train	آموزش	Knowledge Graph	گراف دانش
Variational Autoencoder	خود رمزگذار وردشی	Latent	نهان

Abstract

Lots of essential structures can be modeled as sequences and sequences can be utilized to model the structures like molecules, graphs and music notes. On the other hand, generating meaningful and new sequences is an important and practical problem in different applications. Natural language translation and drug discovery are examples of sequence generation problem. However, there are substantial challenges in sequence generation problem. Discrete spaces of the sequence and challenge of the proper objective function can be pointed out.

On the other, the baseline methods suffer from issues like exposure bias between training and test time, and the ill-defined objective function. So, the necessity of new methods is available.

In recent years, there has been development in image generation by usage of generative adversarial networks (GANs). These networks have attracted attention for sequence generation lately, but since sequences are discrete, this cannot be done easily, and new approaches like reinforcement learning and approximation should be utilized. Furthermore, the problem of instability in generative adversarial networks causes new challenges.

In this research, based on the idea of generative adversarial models, a new iterative method is proposed for sequence generation problem, such that in every step of the algorithm, the model is trained against itself by using the generated samples. The idea of the proposed method is based on the ratio estimation which enables the model to overcome the problem of discreteness in data. Also, the proposed method is more stable than the other GAN-based methods. It also should be noted that the exposure bias problem does not exist in the proposed method.

Since the evaluation of the generated sequences is also an essential challenge in the field of sequence generation, we reviewed the evaluation criterion for sequence generation and also proposed three new methods for evaluating the new sequences which in contrast to previous criterions, examines both the quality and diversity of the new samples.

Experiments show the superiority of the proposed method to previous methods.

Keywords: *Sequence Generation, Adversarial Networks, Neural Network, Deep Learning*



Sharif University of Technology
Department of Computer Engineering

M.Sc. Thesis
Artificial Intelligence

Topic
Adversarial Networks for Sequence Generation

By
Ehsan Montahaei

Supervisor
Dr. M. Soleymani

Winter 2018

